



Aktivní učení pro sémantickou segmentaci mračen 3D bodů

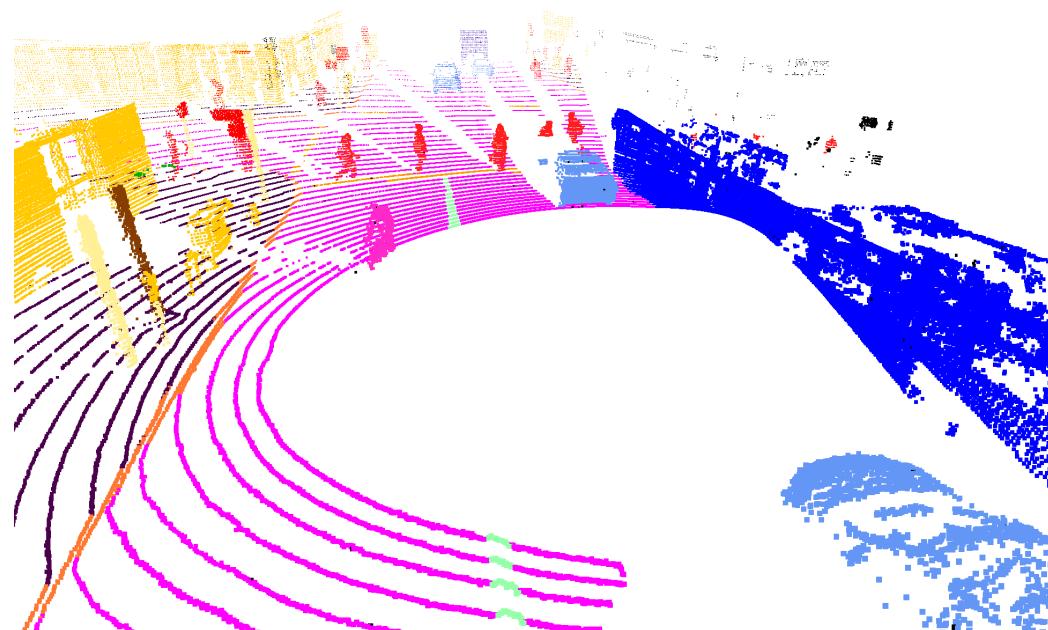
Fakulta Elektrotechnická
Vedoucí: prof. Ing. Tomáš Svoboda, Ph.D.
Petr Šebek
13.6.2023

LiDARová data

- 3D mračna bodů
 - množina bodů v kartézských souřadnicích
- Neuspořádaná / bez struktur



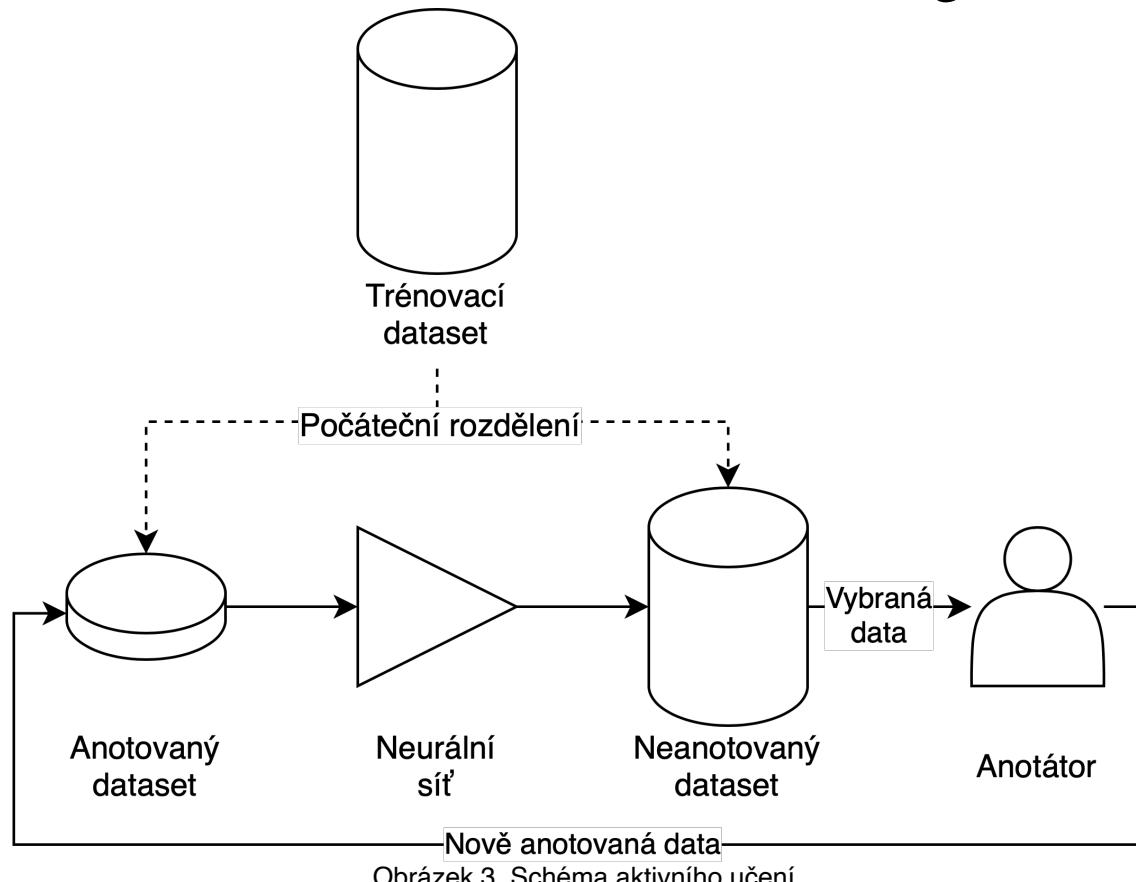
Obrázek 1. LiDARový senzor



Obrázek 2. 3D mračno bodů

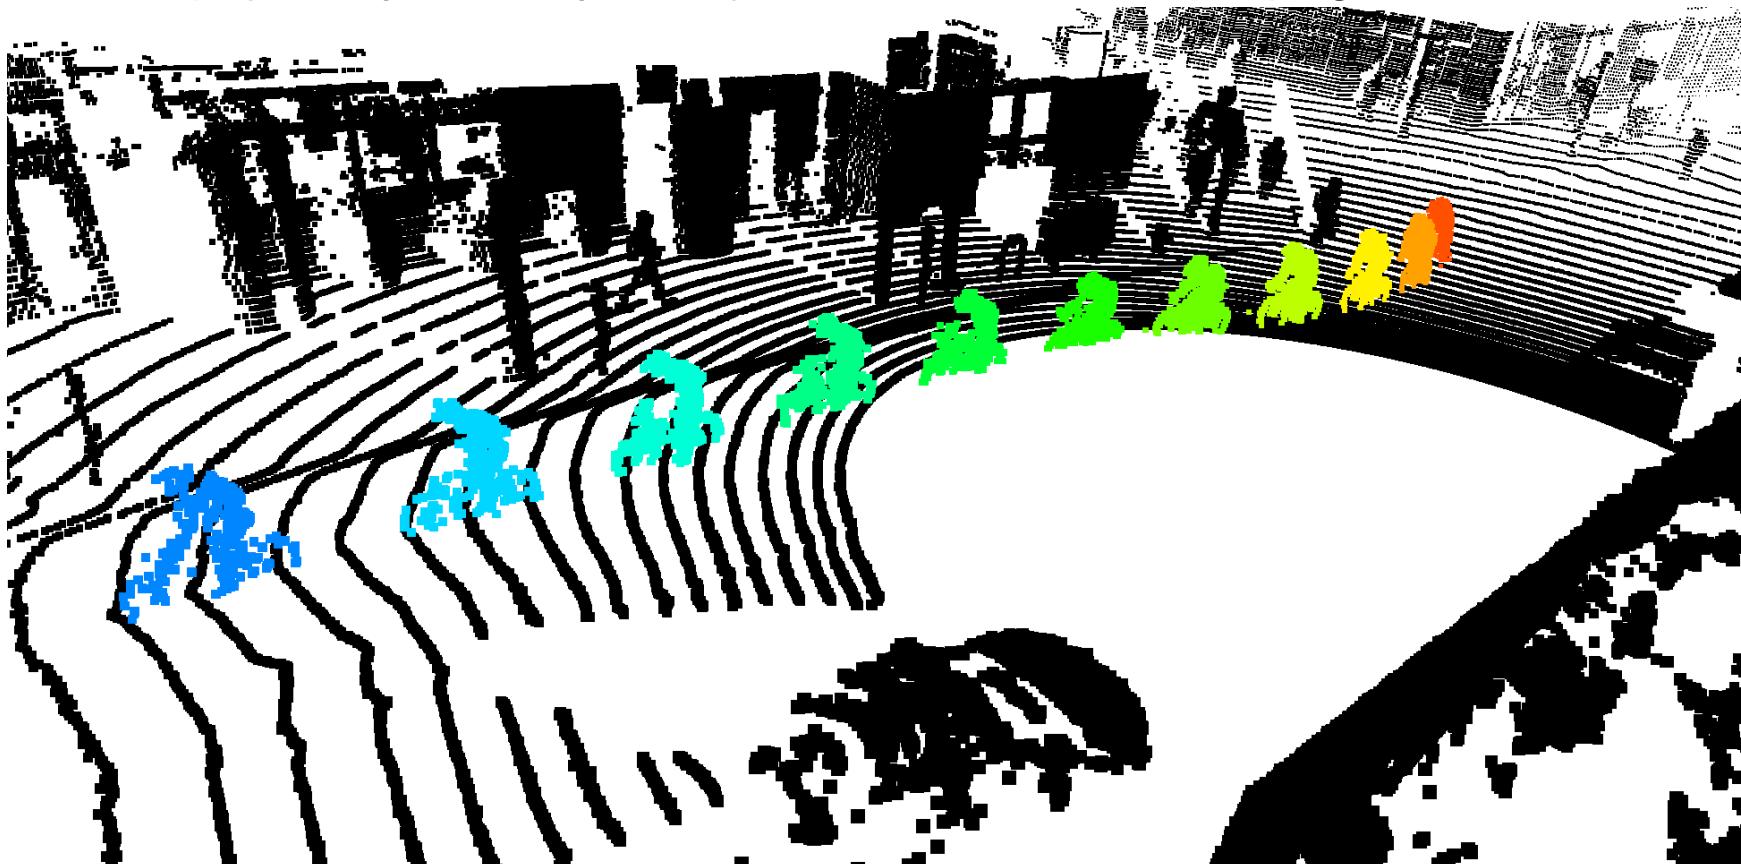
Aktivní učení

- Iterativní algoritmus
- Anotují se pouze „zajímavé“ scény
 - Pomocí např. softmax-entropy: $H = -P \log(P)$



Cíl práce

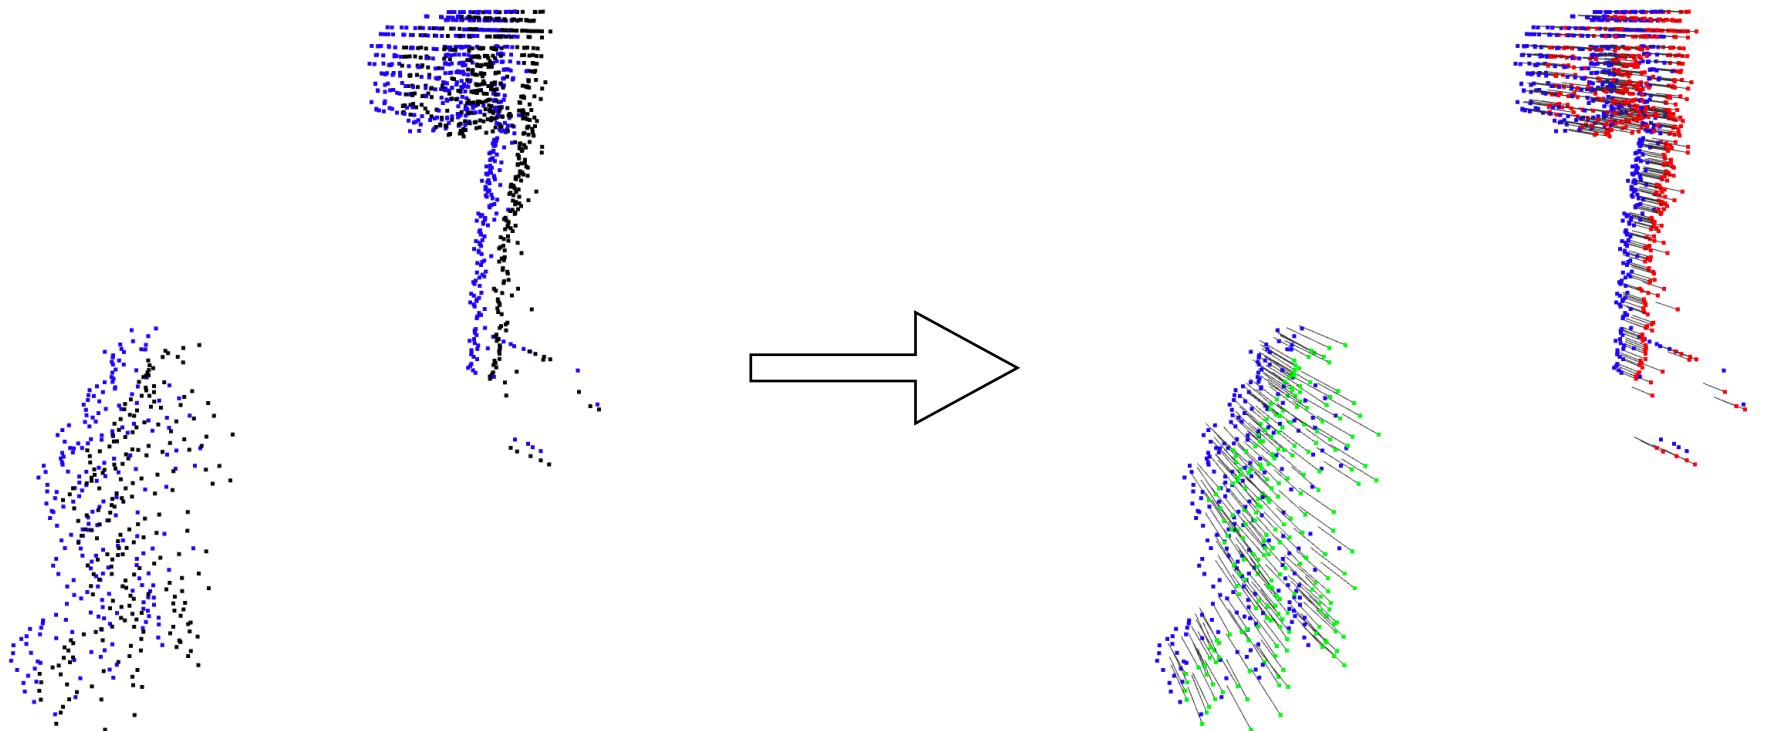
- Rozšíření ReDALu*
- Propojení dynamických objektů skrz čas → propagace anotace



Obrázek 4. Dynamický objekt propojený skrz čas

Postup Motion flow

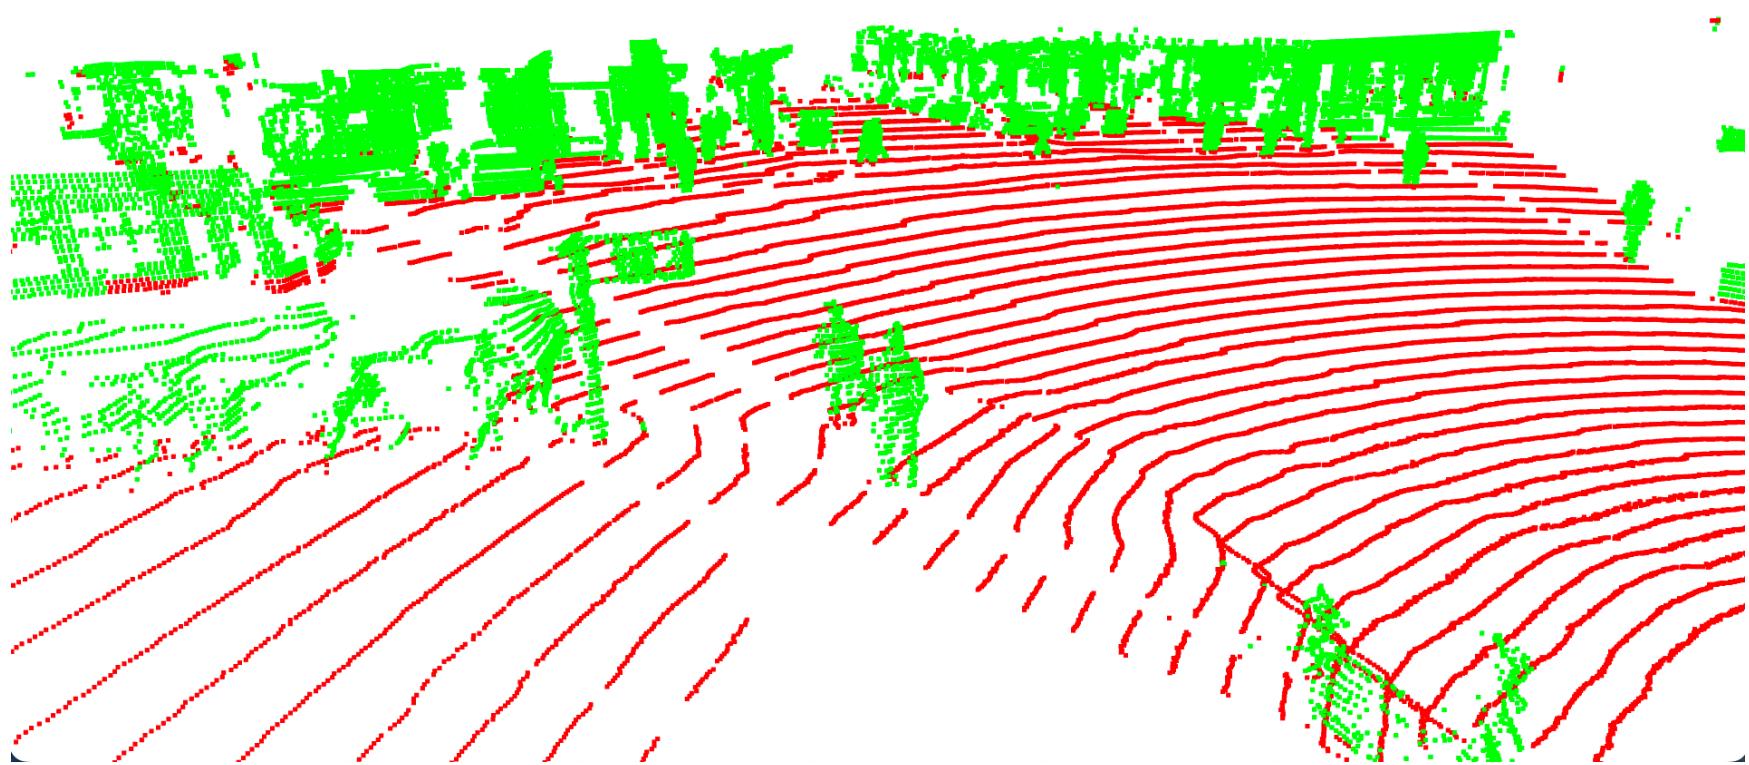
- SLIM*
 - Segmentace dynamické, nebo statické body
 - Pohyb pro každý bod do následující scény



Obrázek 5. Predikce SLIMu

Postup Odstranění země

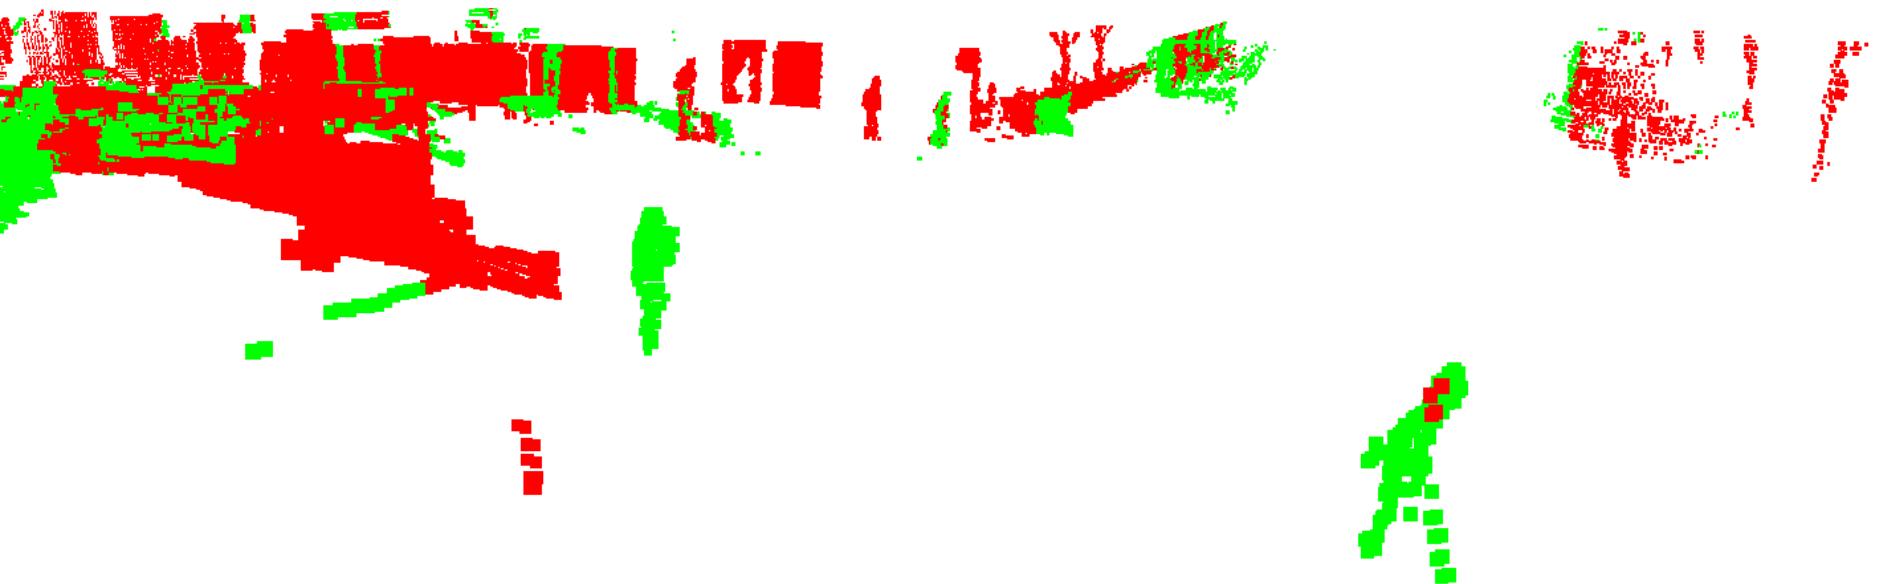
- Patchwork++*



Obrázek 6. Segmentace země

Postup Motion flow

- Predikce dynamické vs. statické jsou zašuměné



Obrázek 7. Predikce SLIMu

Postup DBSCAN*

- Získání jednotlivých instancí

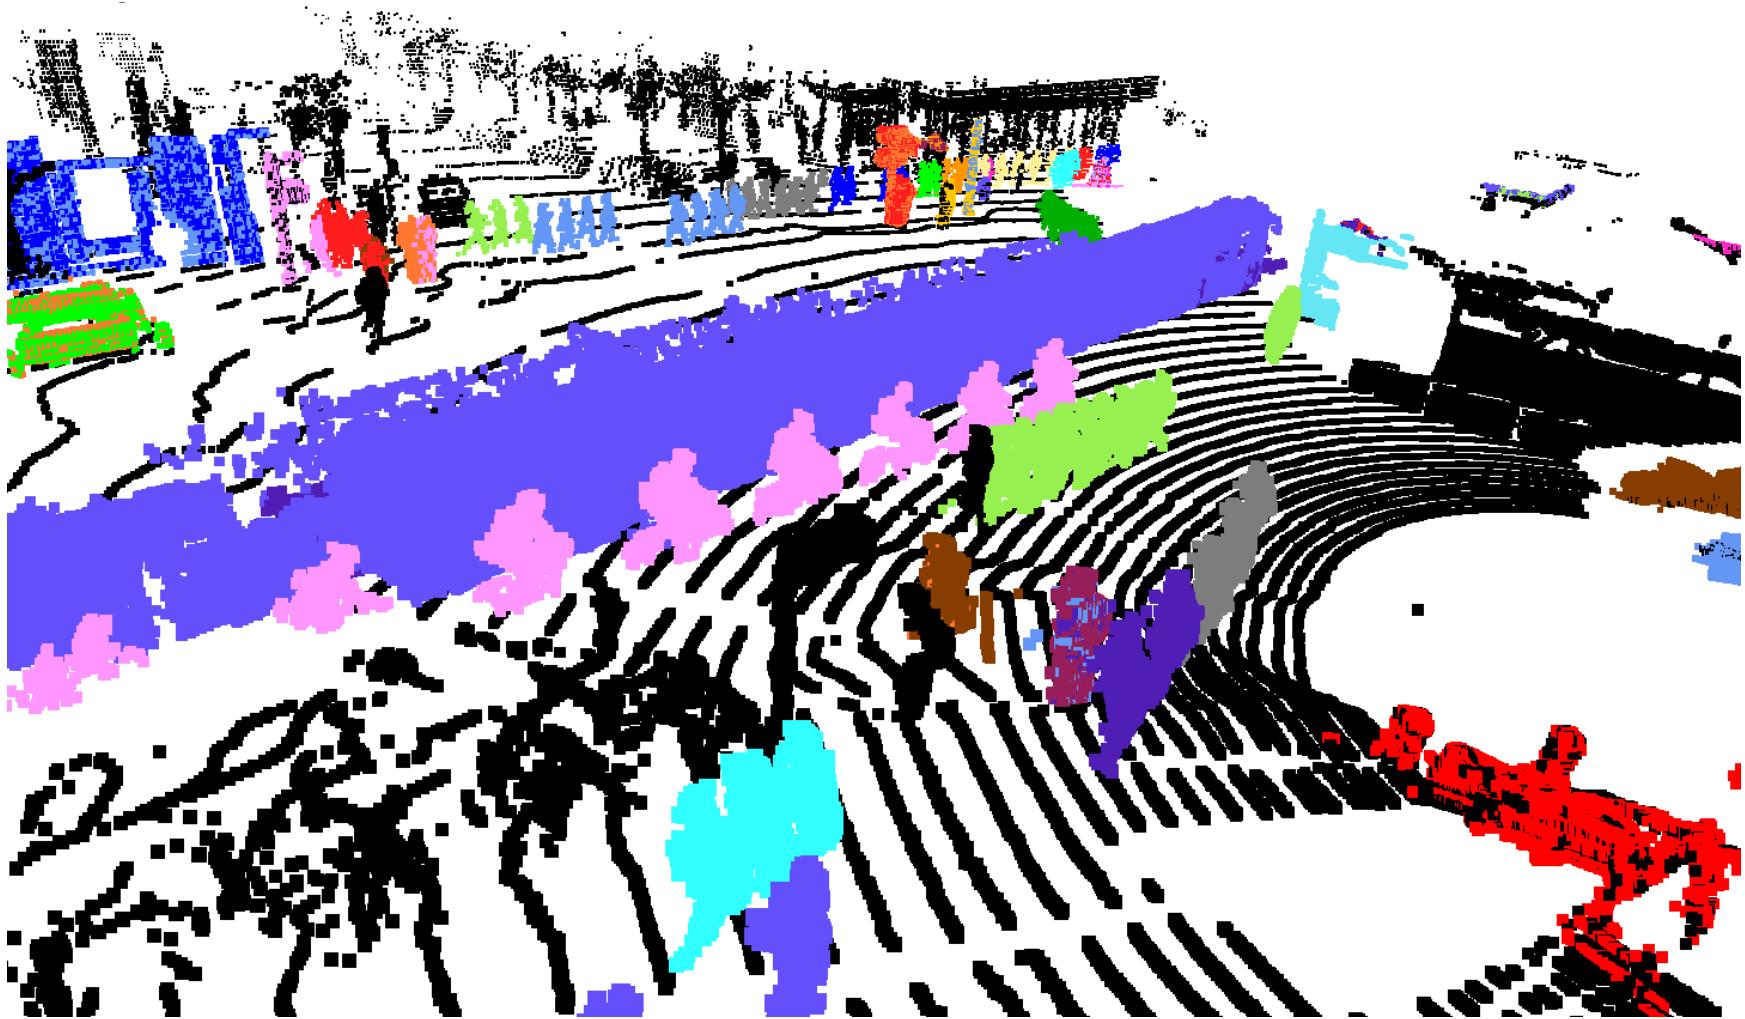


Obrázek 8. Clustery scény získané pomocí DBSCANu

*Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. In *Knowledge Discovery and Data Mining*, 1996

Postup

Dynamické instance propojené v čase



Obrázek 9. Dynamické objekty propojené skrz čas

Datasets



SemanticKITTI

- 19 130 trénovacích scén
- 4 071 validačních scén

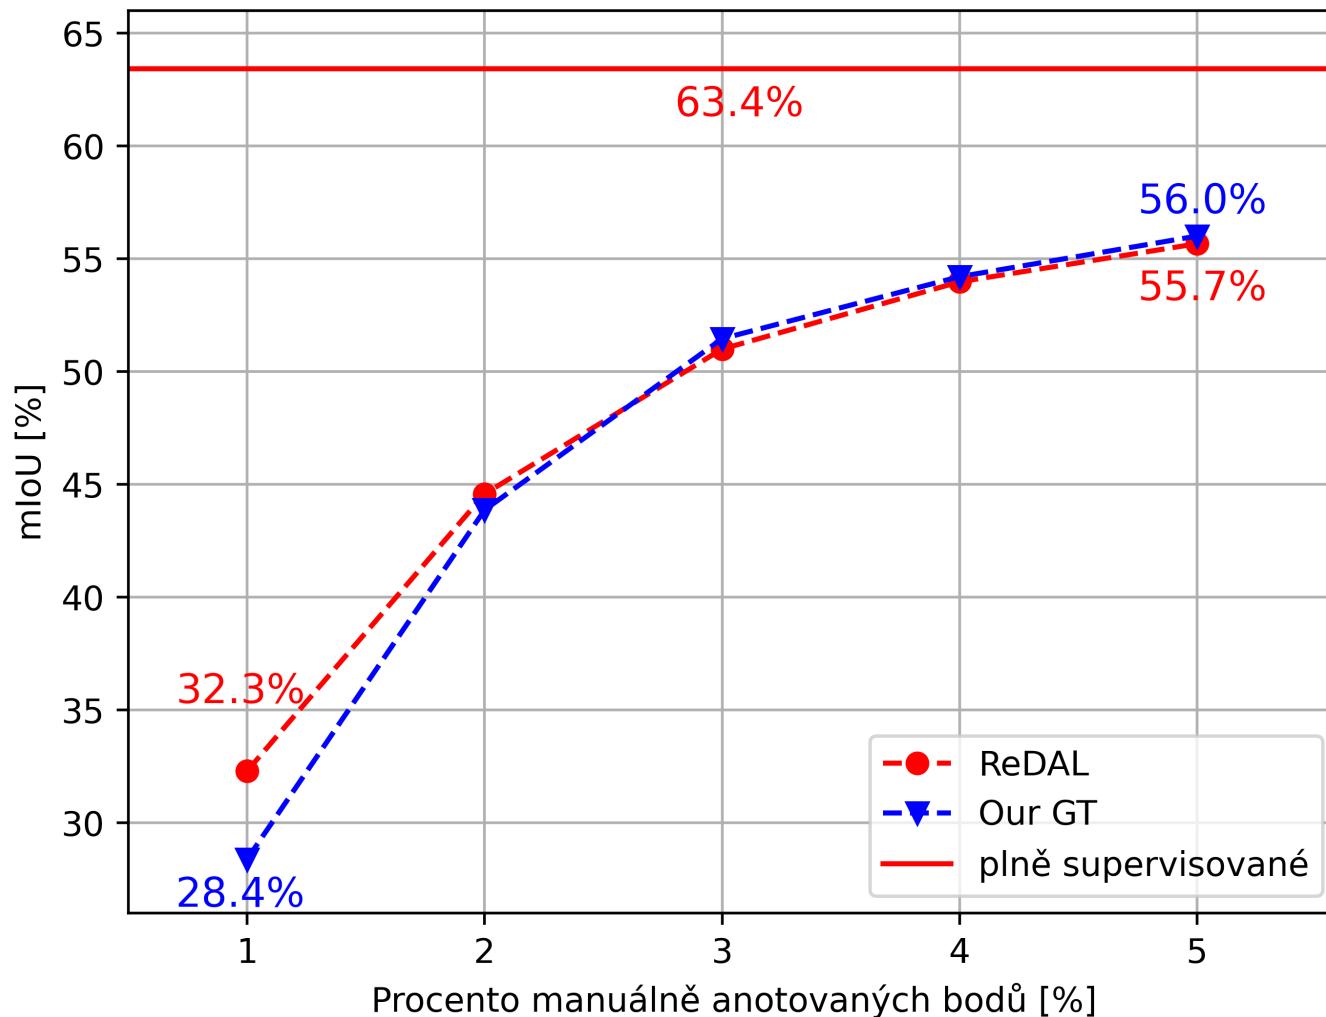
Waymo Open Dataset (subset)

- 19 526 trénovacích scén
- 4 165 validačních scén

Experimenty s instancemi na základě ground truth anotací

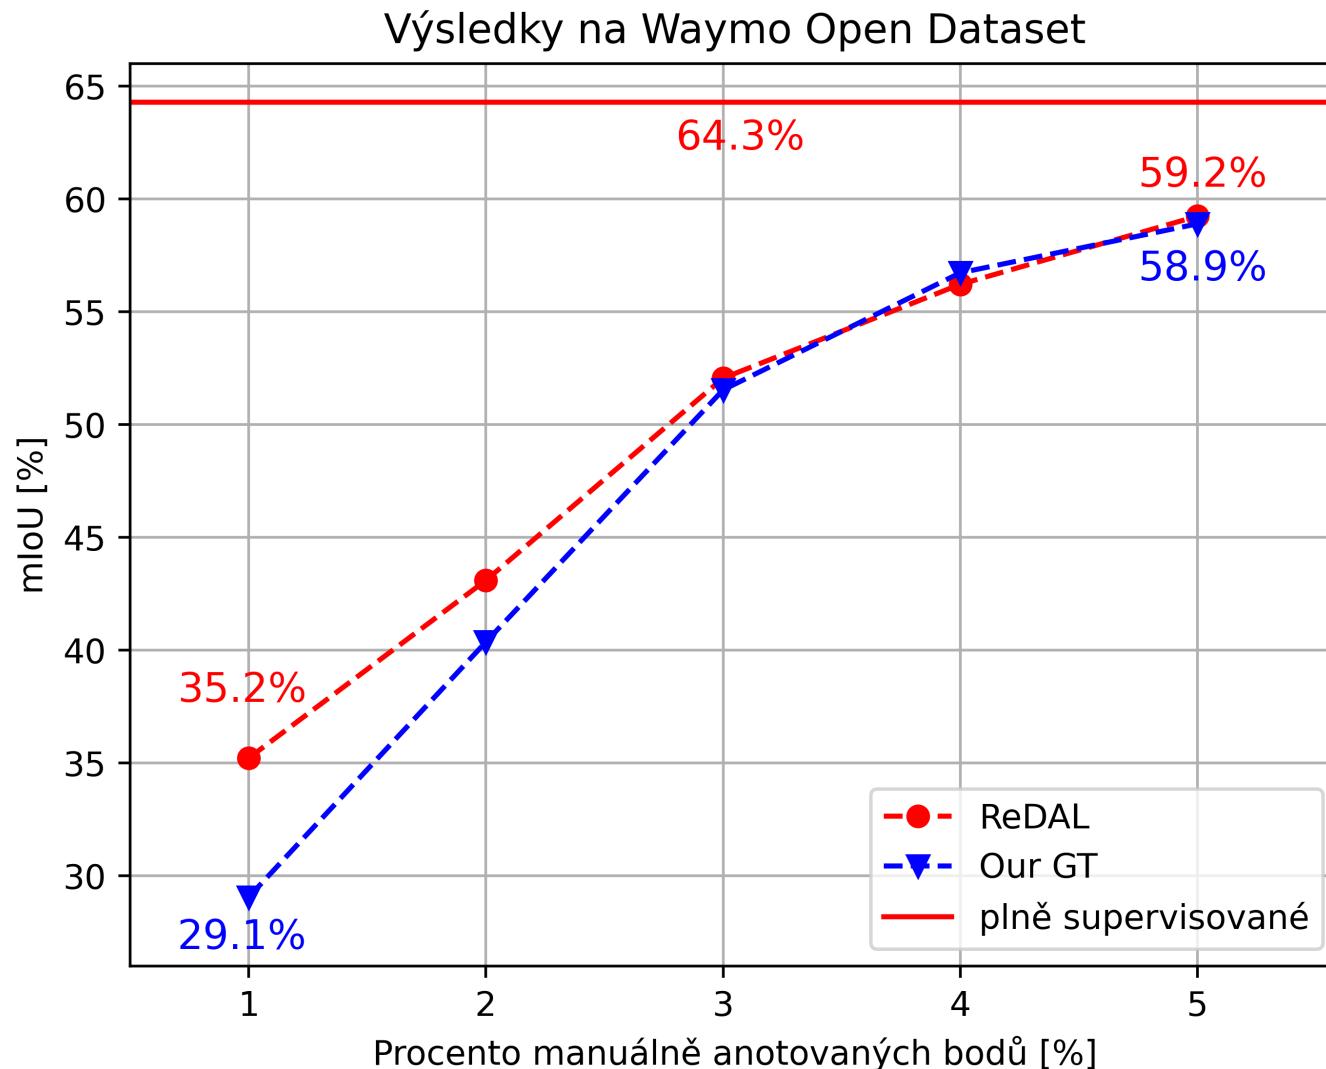
Výsledky SemanticKITTI

Výsledky na SemanticKITTI



Graf 1. Výsledky na SemanticKITTI

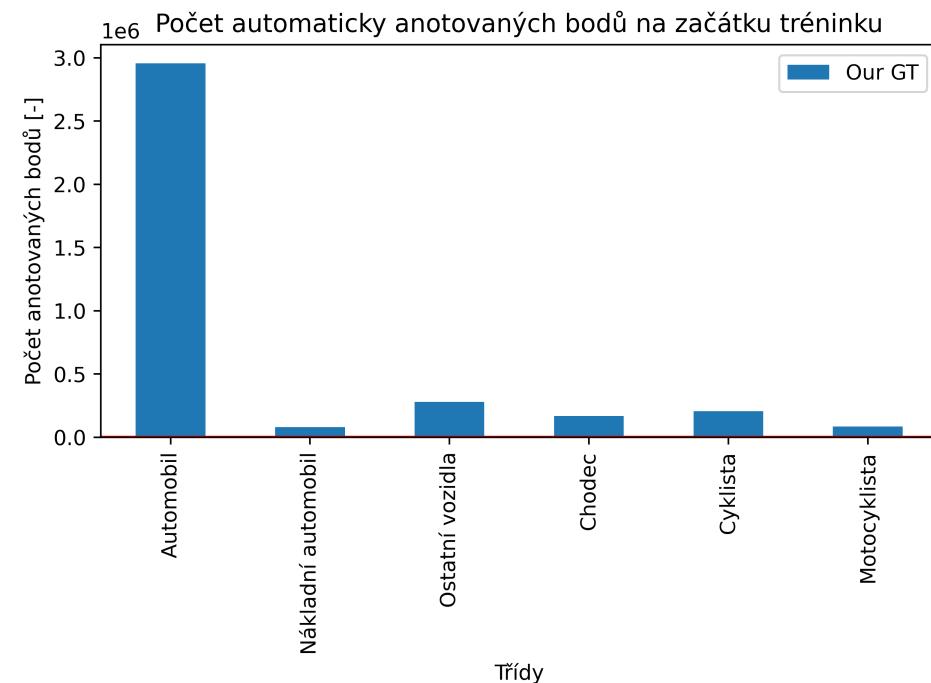
Výsledky Waymo Open Dataset



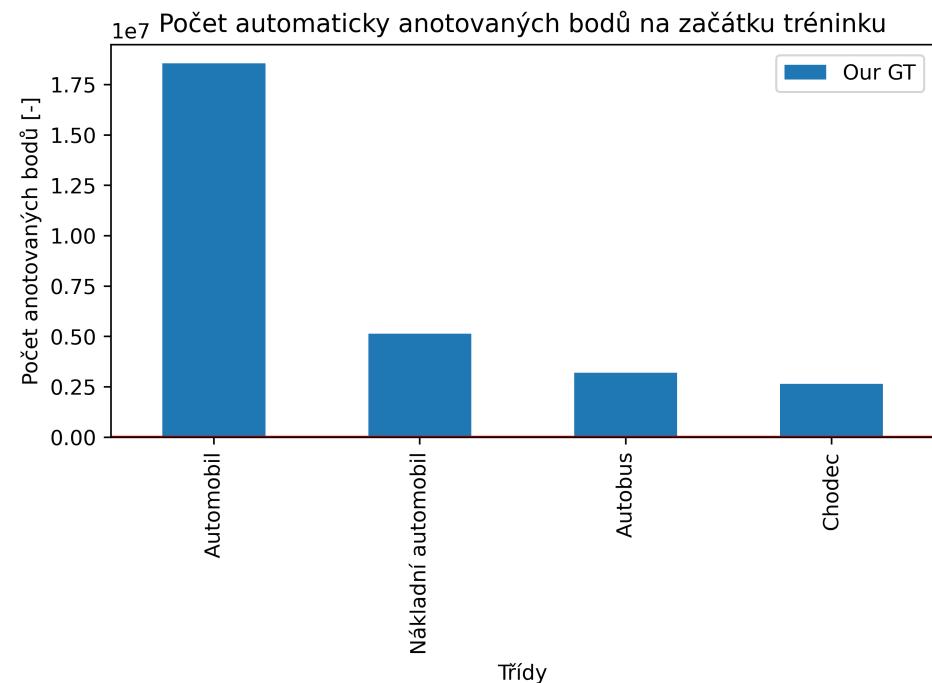
Graf 2. Výsledky metody založené na ground truth na Waymo Open Datasetu

Výsledky

Nevyvážený dataset



Graf 3. Počet automaticky anotovaných bodů na začátku tréninku na SemanticKITTI



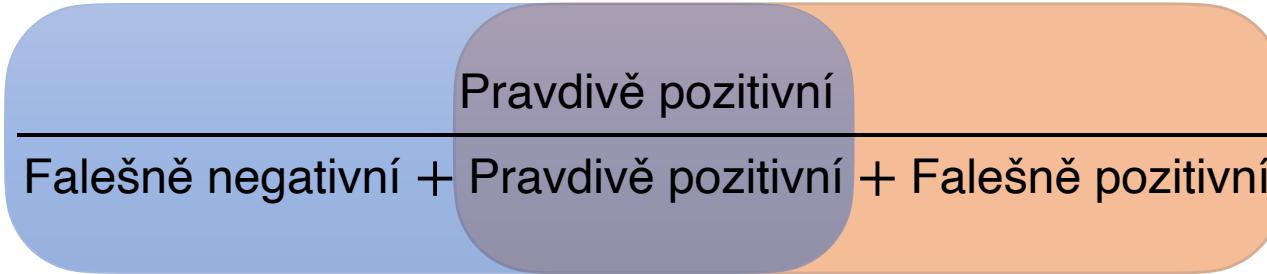
Graf 4. Počet automaticky anotovaných bodů na začátku tréninku na Waymo Open Datasetu

Výsledky

Nevyvážený dataset

$$\text{IoU} = \frac{\text{Pravdivě pozitivní}}{\text{Falešně negativní} + \text{Pravdivě pozitivní} + \text{Falešně pozitivní}}$$

Recall Precision



- Recall - procento detekovaných objektů
- Precision - věrohodnost detekce

Výsledky

Nevyvážený dataset

Precision

Třída	Our GT	ReDAL*	Třída	Our GT	ReDAL*
Automobil	0.73	0.90	Automobil	0.96	0.96
Nákladní automobil	0.13	0.21	Nákladní automobil	0.17	0.10
Ostatní vozidla	0.13	0.30	Ostatní vozidla	0.22	0.02
Chodec	0.07	1.00	Chodec	0.77	0.00
Cyklista	0.13	0.00	Cyklista	0.96	0.00
Motocyklista	0.00	0.00	Motocyklista	0.01	0.00

Tabulka 1. Precision (vlevo) a recall (vpravo) dynamických tříd na SemantiKITTI

Třída	Our GT	ReDAL*	Třída	Our GT	ReDAL*
Automobil	0.70	0.92	Automobil	0.97	0.92
Nákladní automobil	0.19	0.43	Nákladní automobil	0.78	0.42
Autobus	0.24	0.36	Autobus	0.54	0.41
Chodec	0.28	0.82	Chodec	0.93	0.55

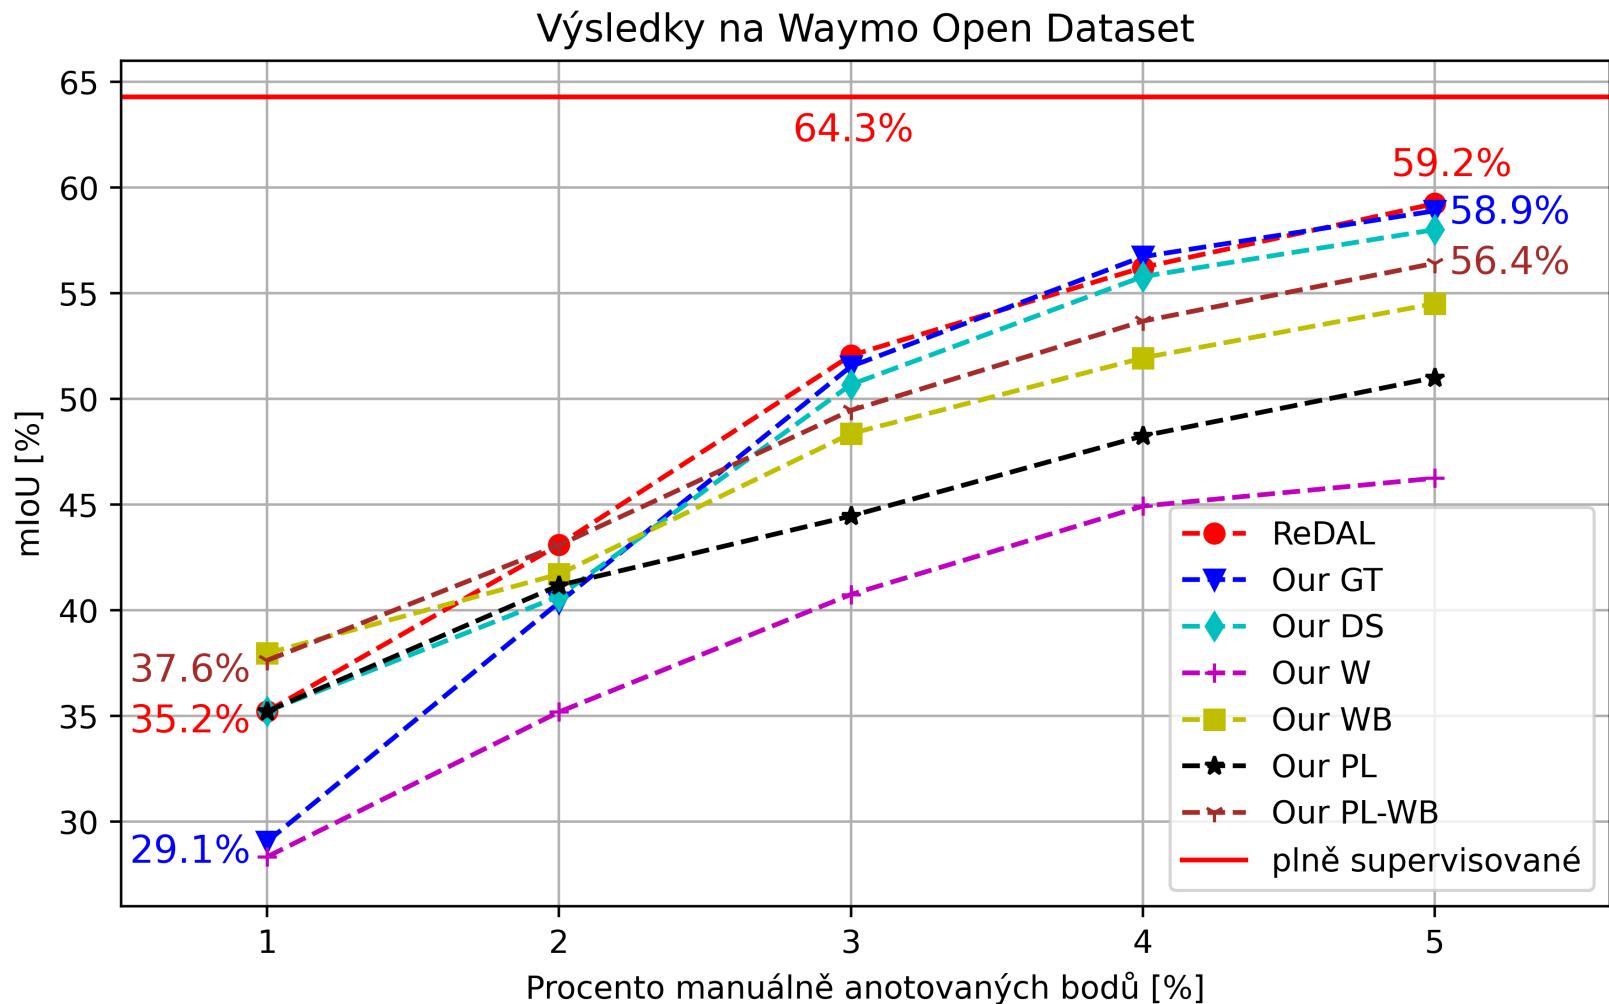
Tabulka 2. Precision (vlevo) a recall (vpravo) dynamických tříd na Waymo Open Dataset

Jiné způsoby učení



- Opožděný start (DS)
 - Učení začíná z 1. checkpointu ReDALu
- Váhování ztrátové funkce (W)
- Váhování hodnoty ztrátové funkce (WB)
 - $\mathcal{L} = \frac{1}{|B|} \sum_{b \in B} \mathcal{L}_b \frac{|p_b^l|}{|p_b|}$
- Pseudolabeling (PL)
- Pseudolabeling a váhování hodnoty ztrátové funkce (PL-WB)

Výsledky Waymo Open Dataset

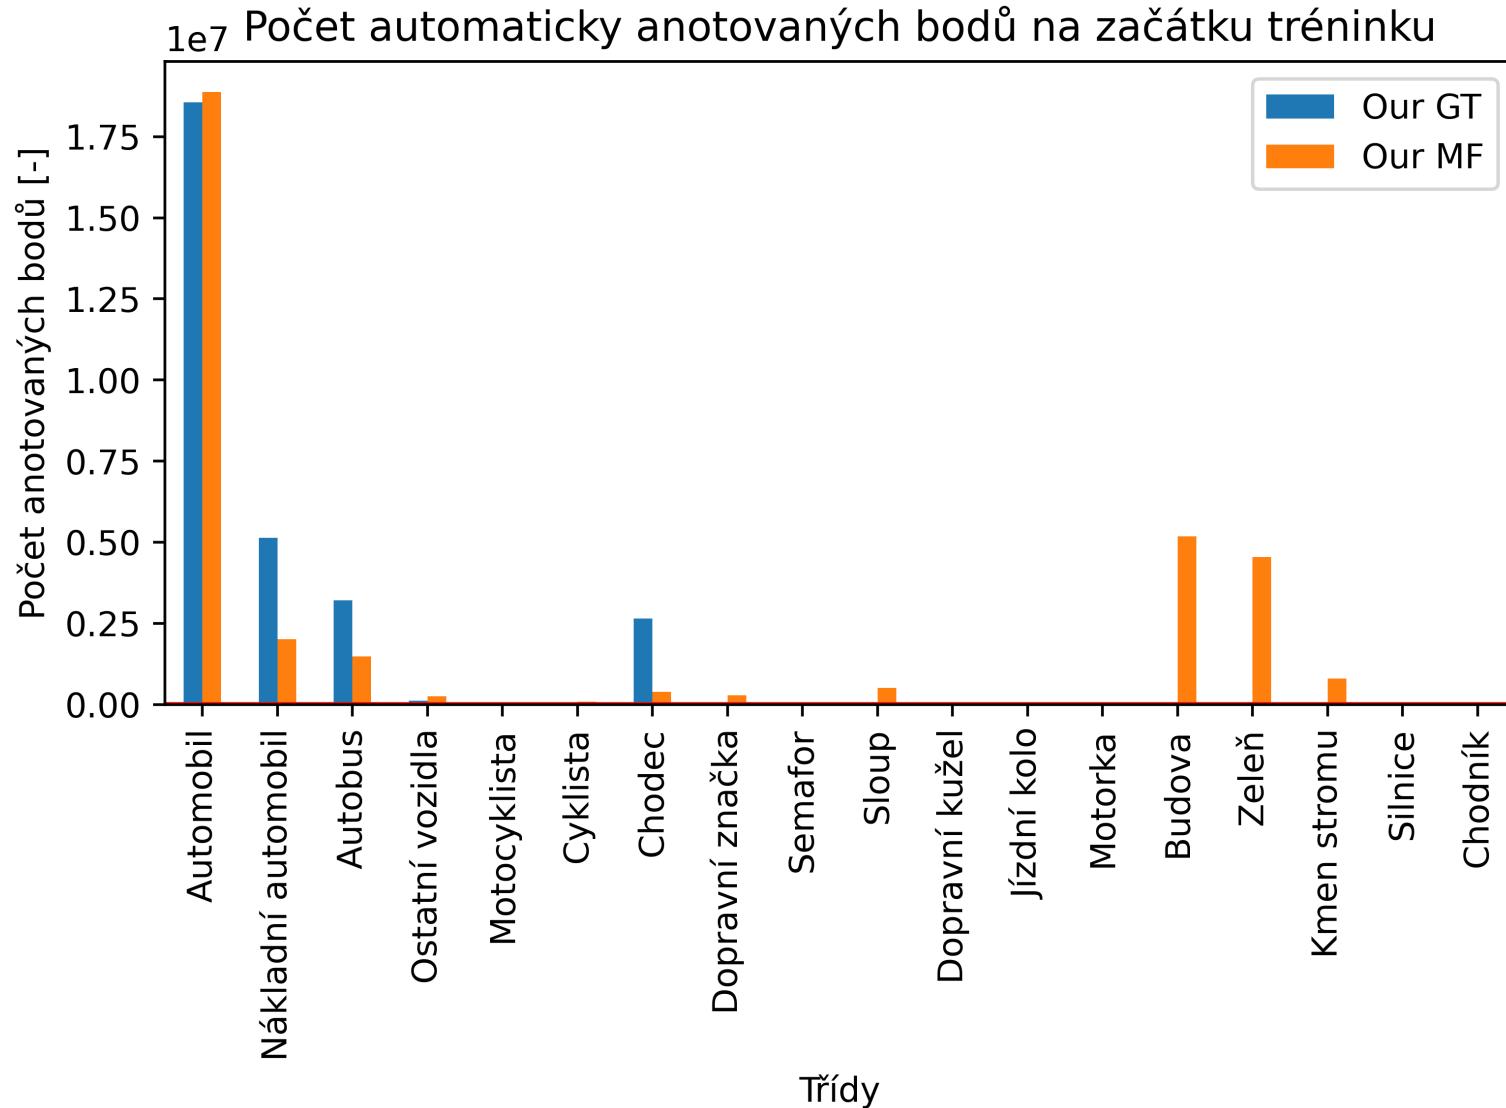


Graf 5. Výsledky metody založené na ground truth na jiných způsobech učení na Waymo Open Datasetu

Experimenty s instancemi vytvořenými naším postupem

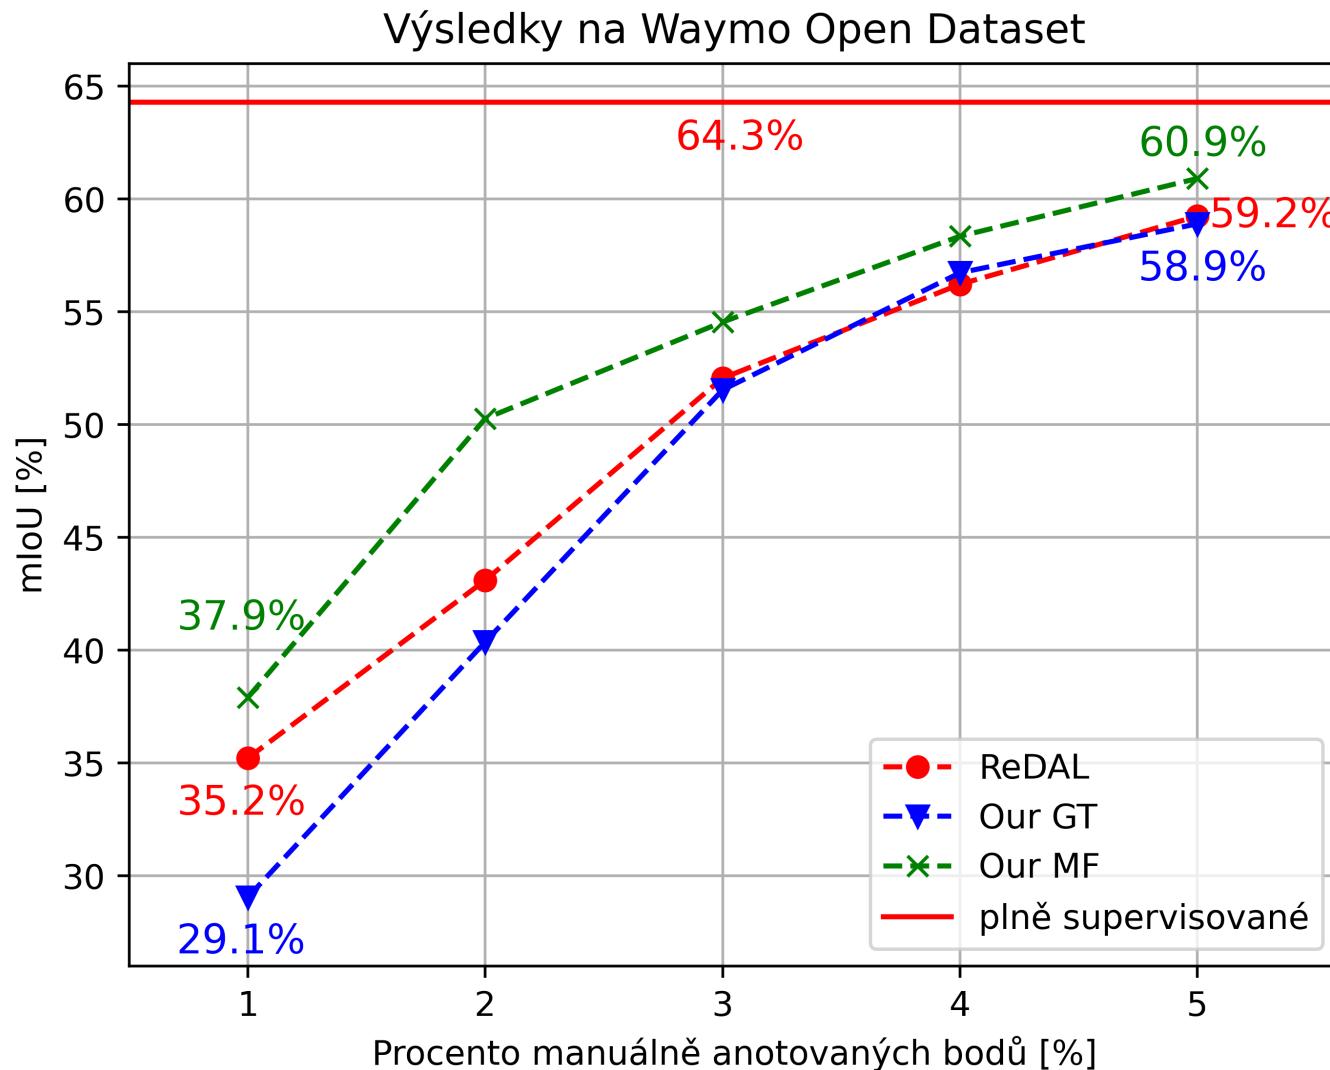
Výsledky

Waymo Open Dataset



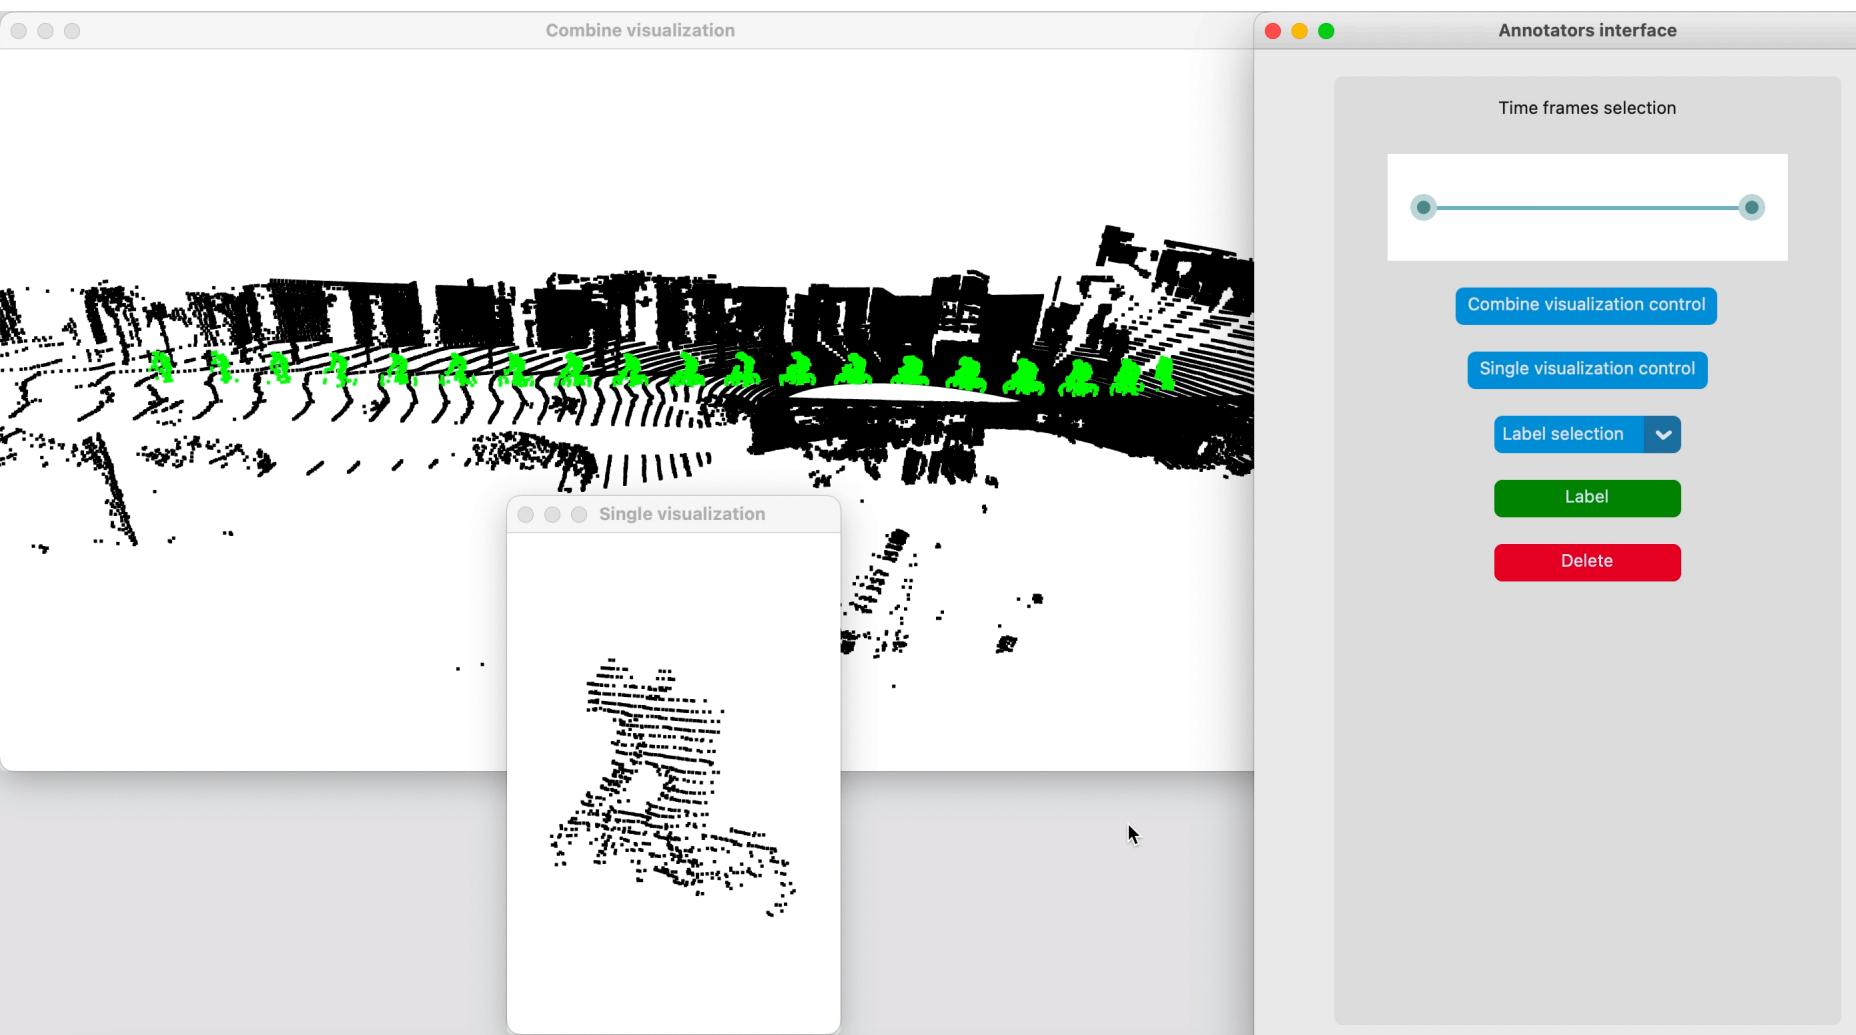
Graf 6. Počet automaticky anotovaných bodů na začátku tréninku na Waymo Open Datasetu

Výsledky Waymo Open Dataset

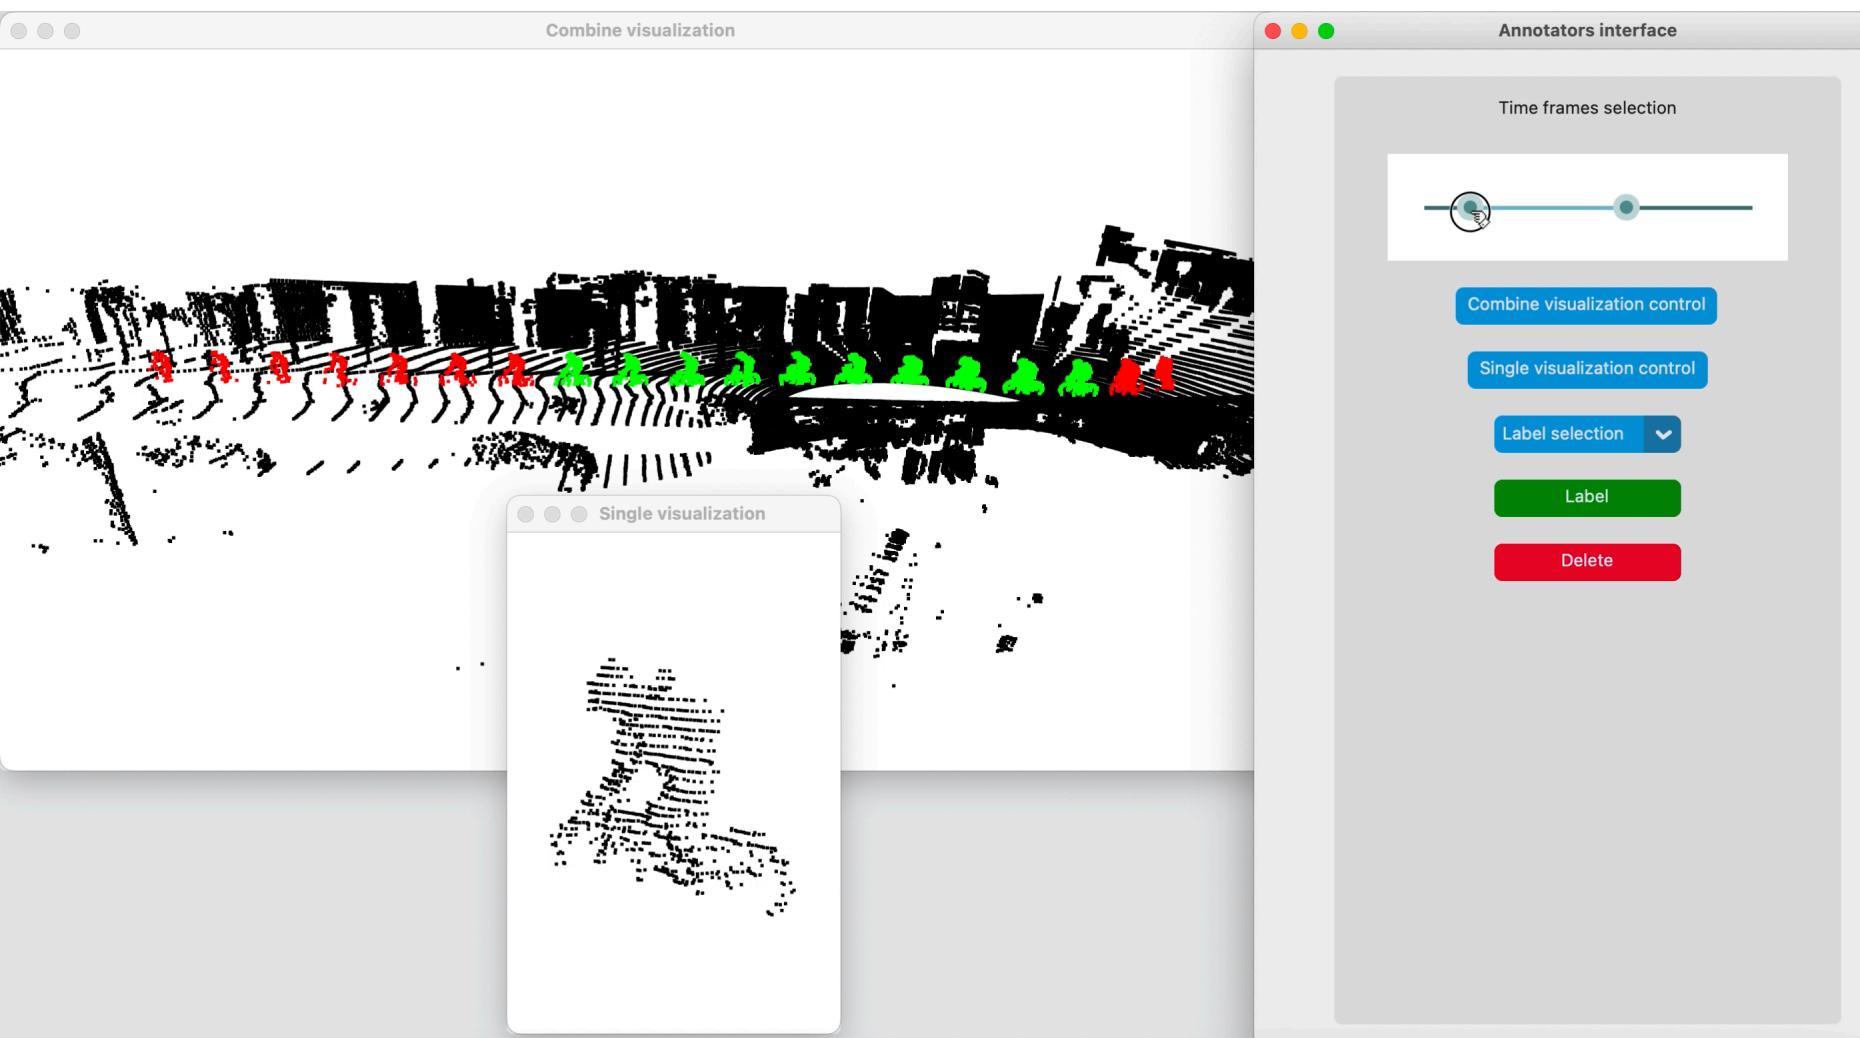


Graf 7. Výsledky na Waymo Open Datasetu

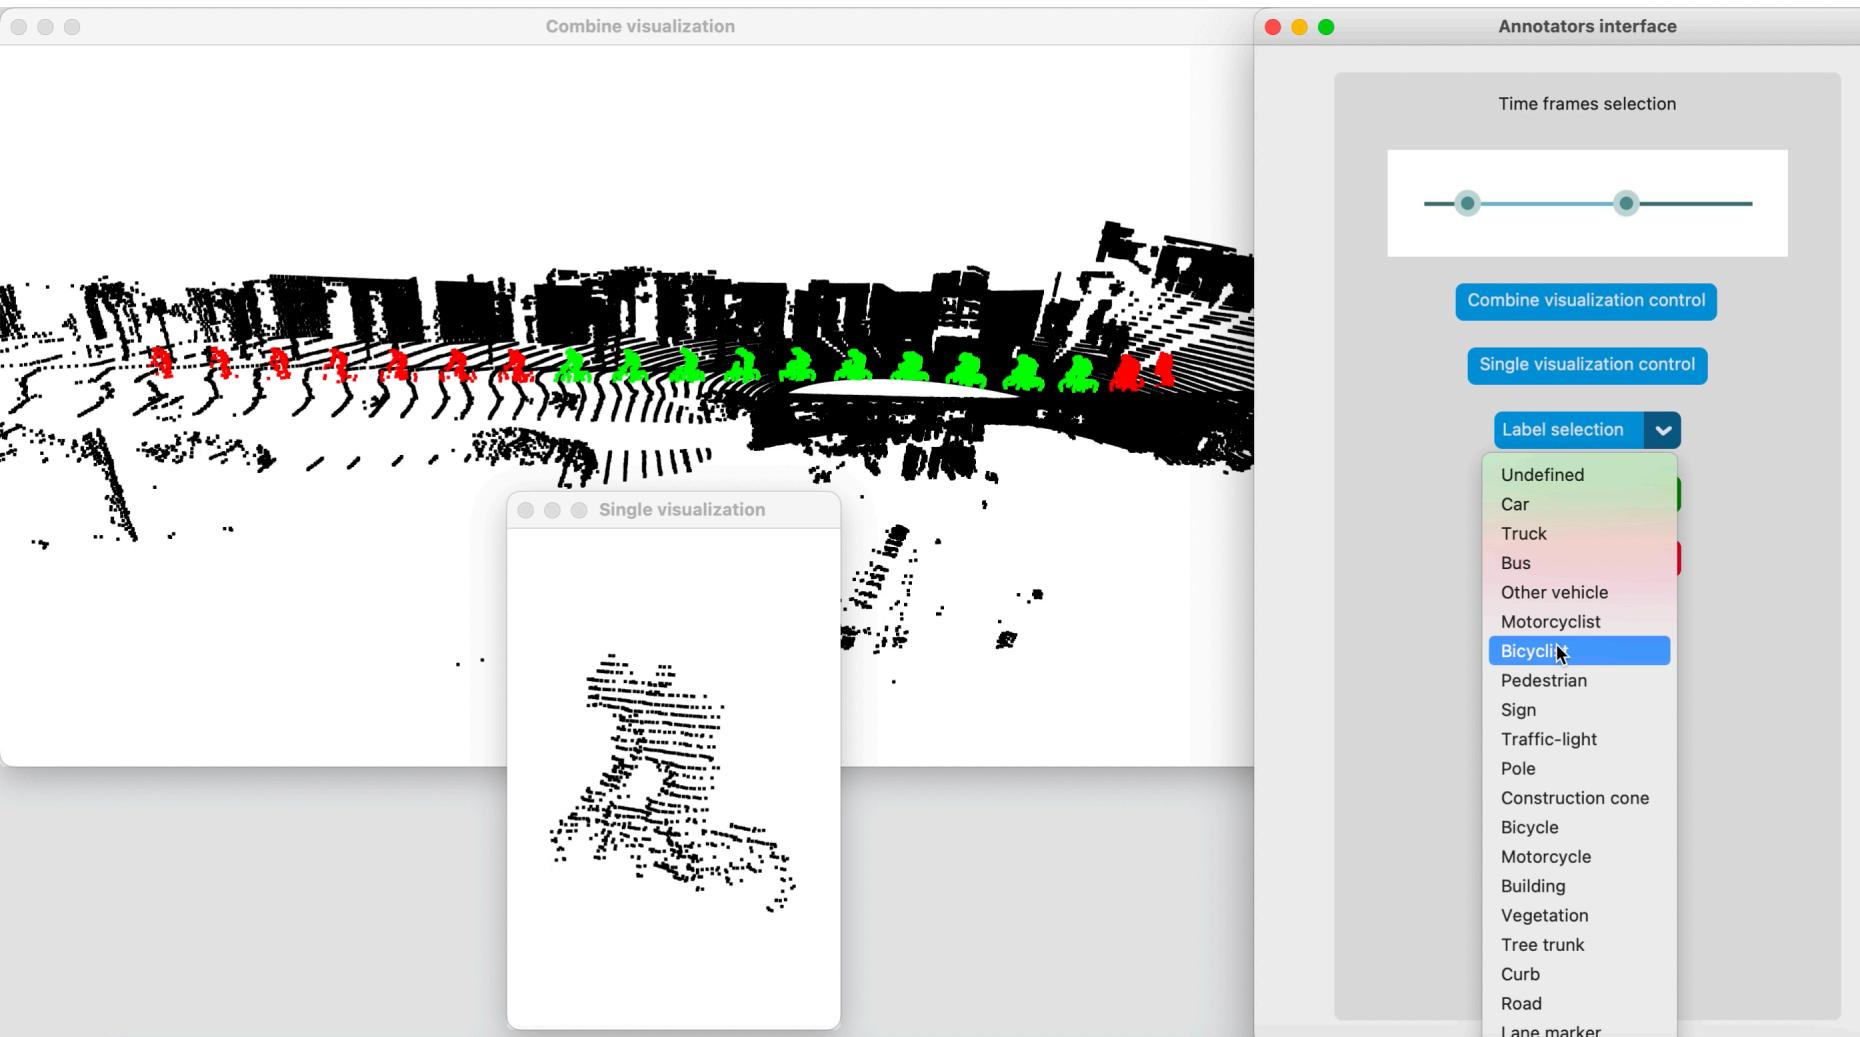
Anotátorské uživatelské rozhraní



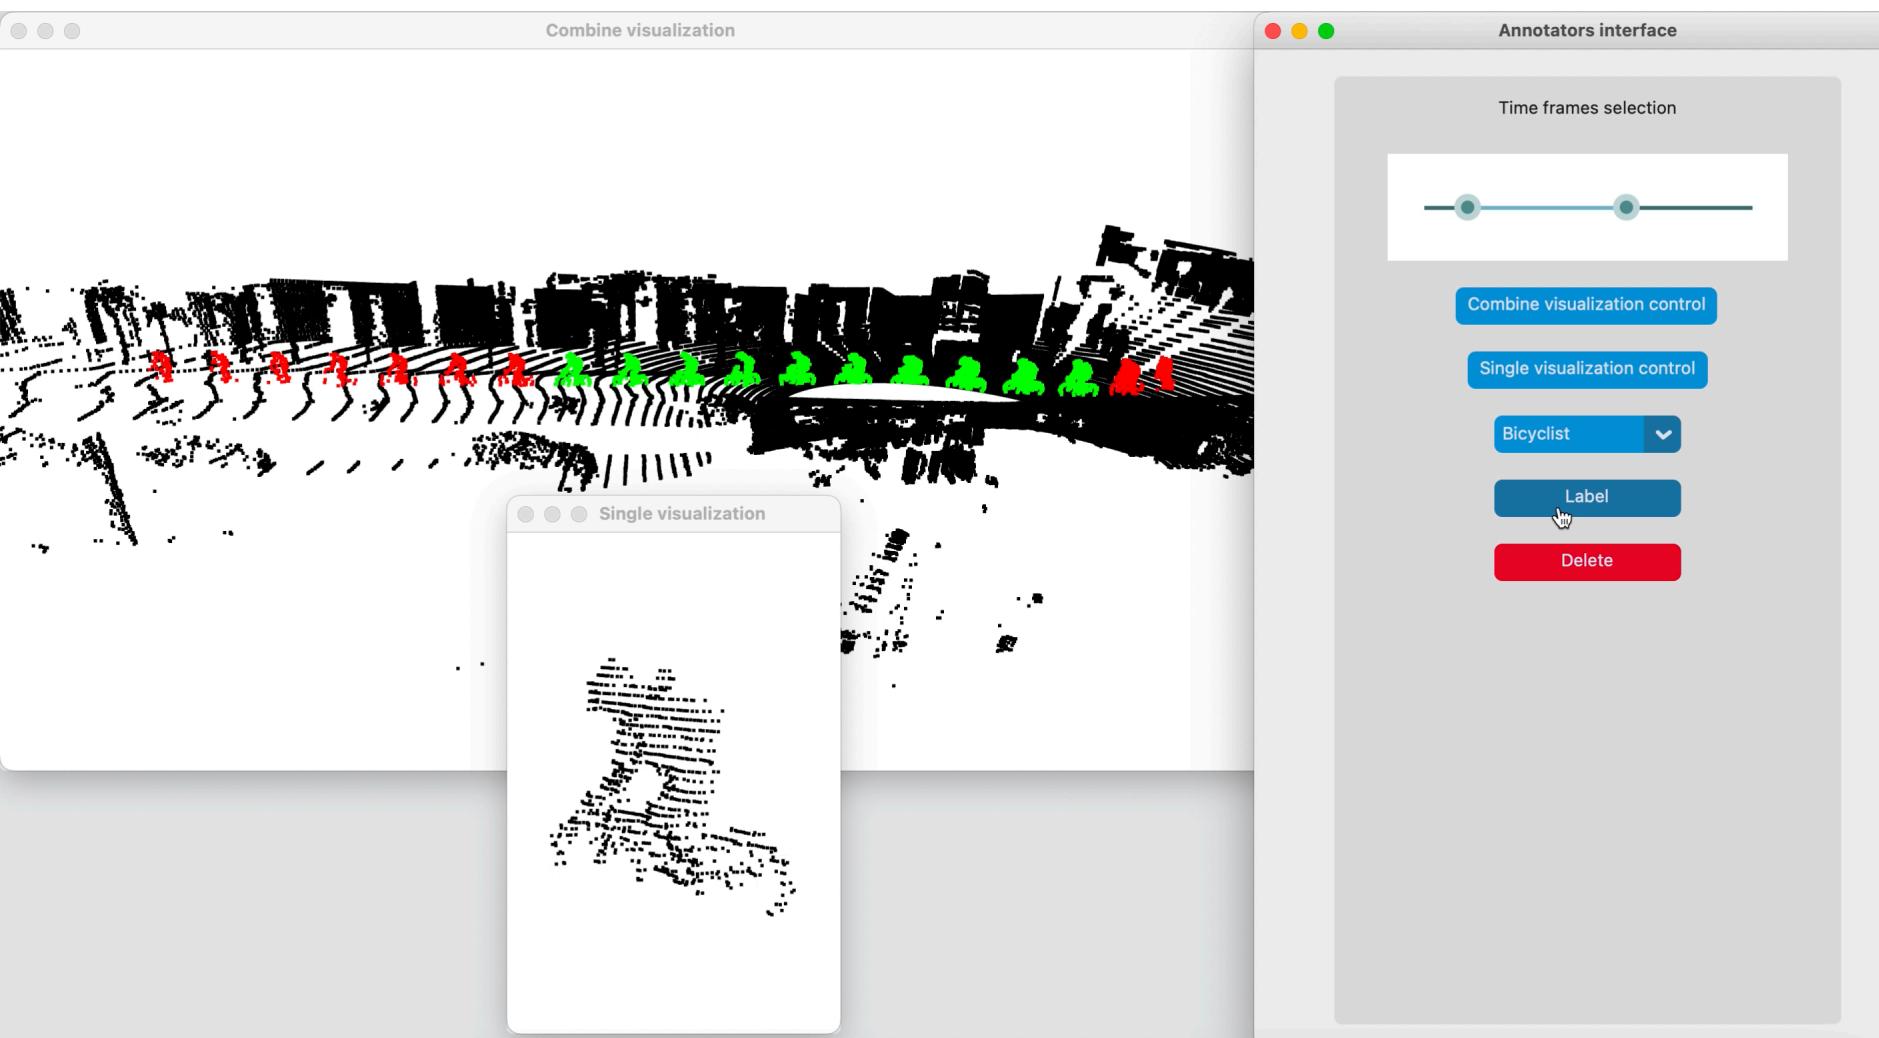
Anotátorské uživatelské rozhraní



Anotátorské uživatelské rozhraní



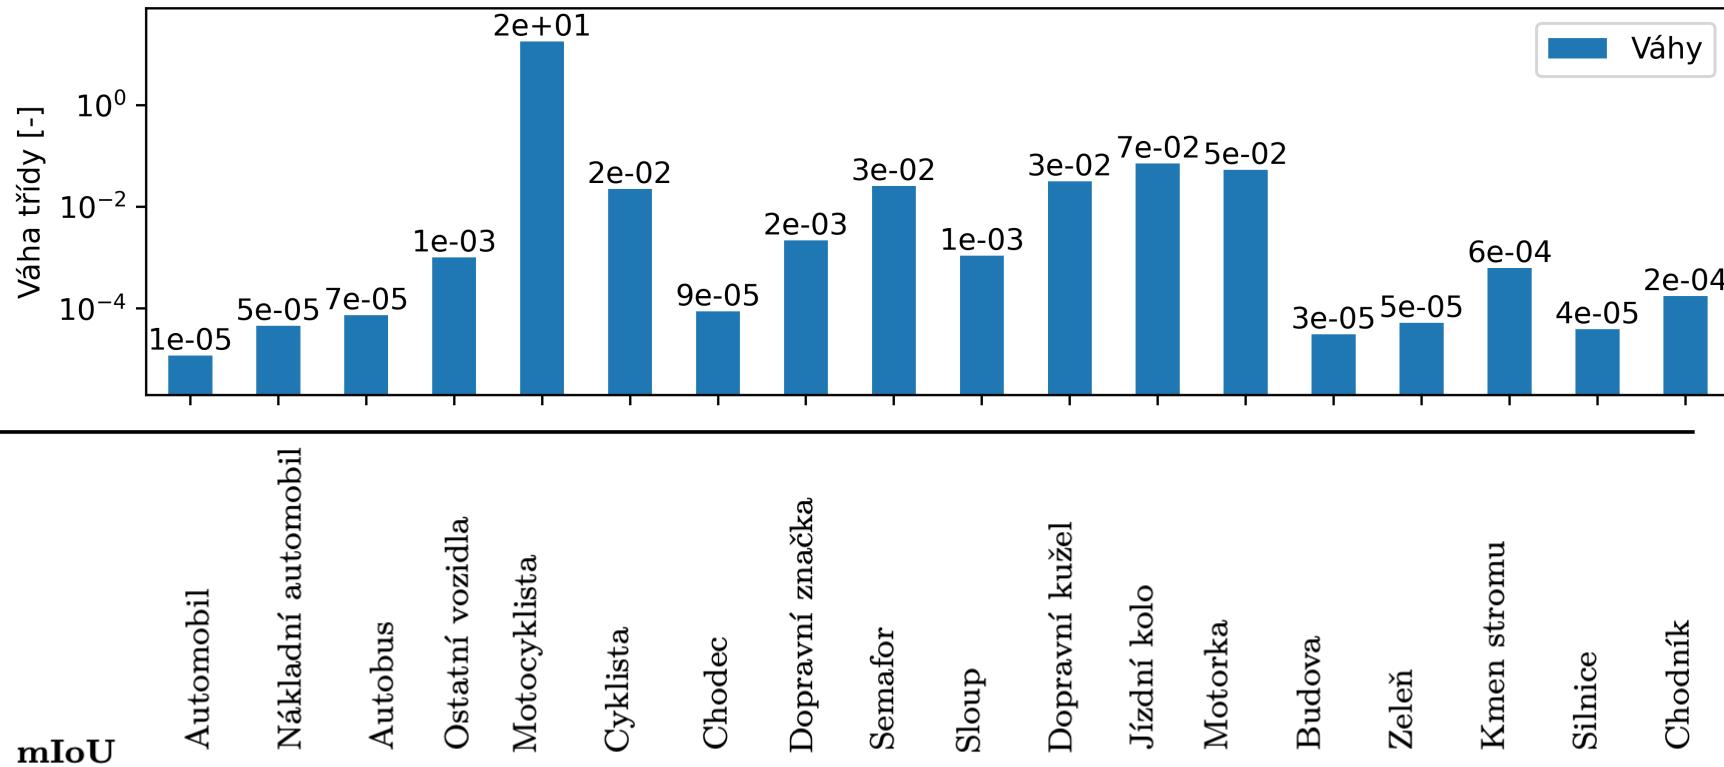
Anotátorské uživatelské rozhraní



Děkuji za pozornost

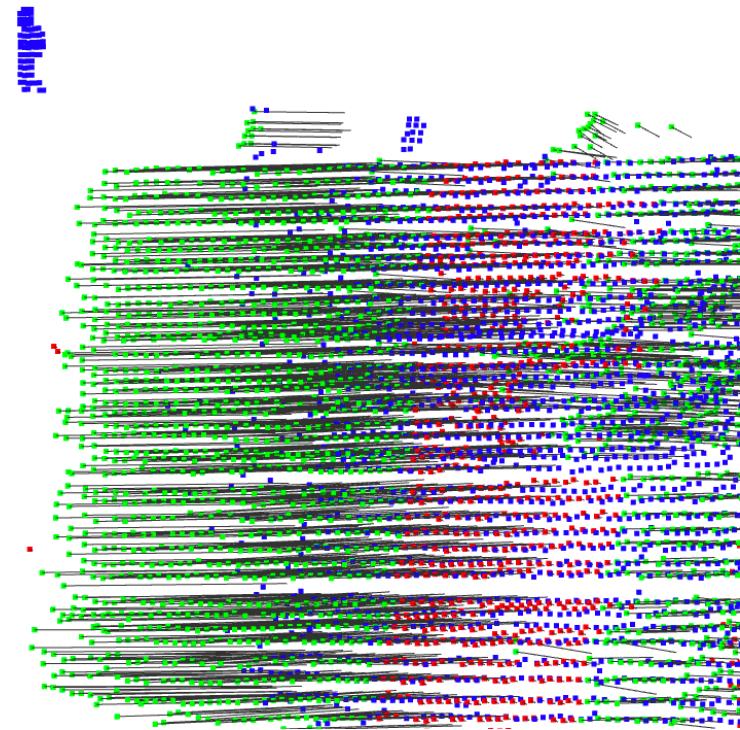
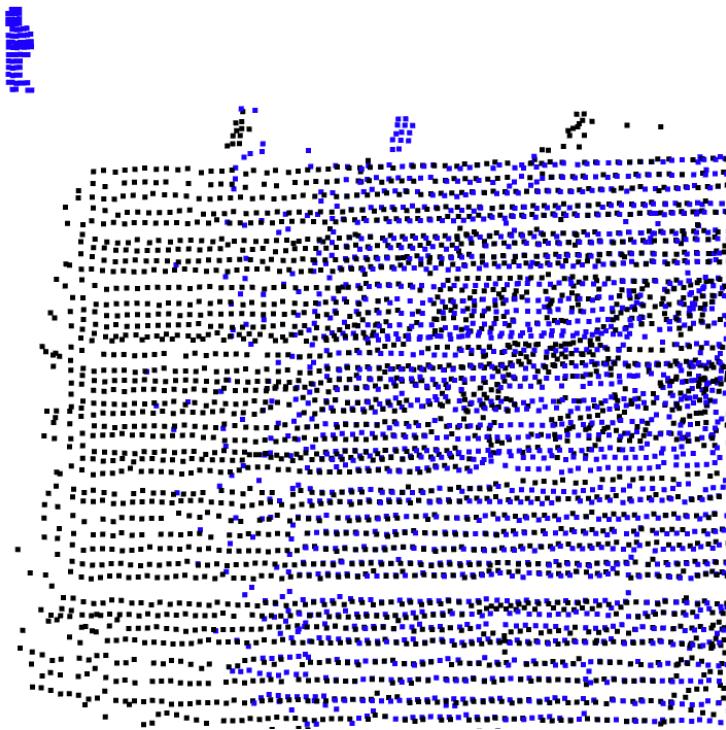
„Additional annotations of cars probably unbalance the dataset in favor of this class and the model starts to predict this class much more, which worsens the precision on this class, as you can see in table 4.3.” Rovnici 3.1 říkáte, že používáte weighting crossentropy loss. Tušíte proč tato metoda nezfungovala na zpětné vybalancování tříd?

Váhy tříd na začátku tréninku

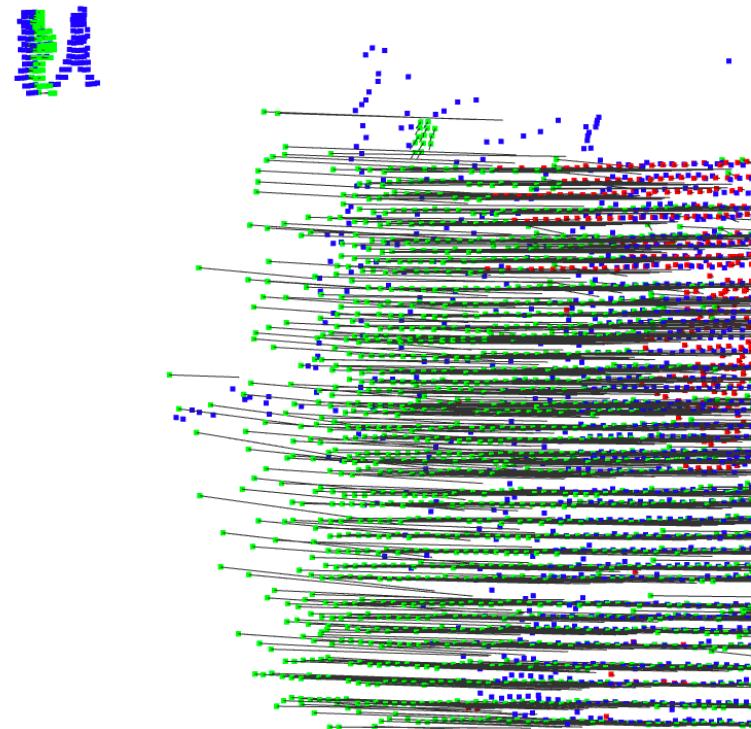
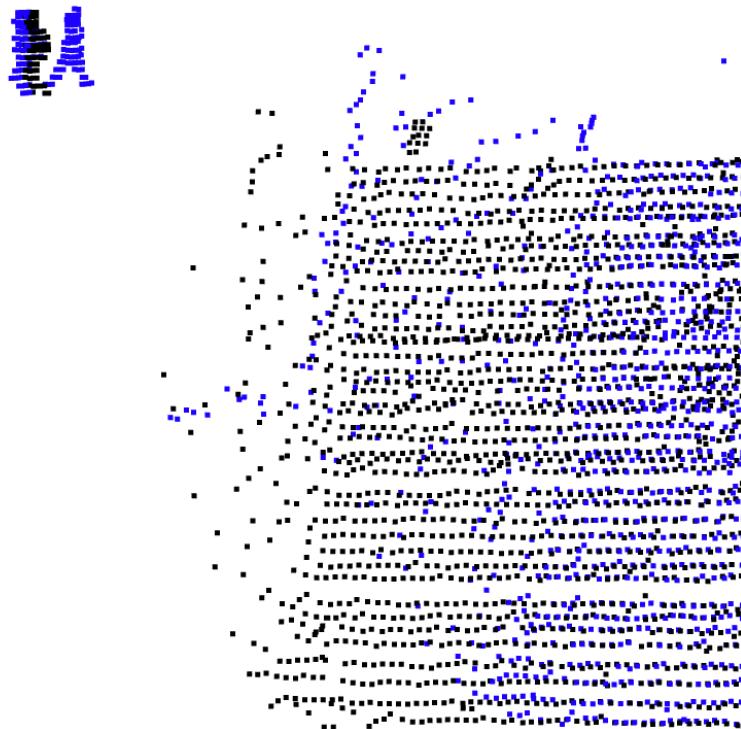


mIoU	Automobil	Nákladní automobil	Autobus	Ostatní vozidla	Motocyklista	Cyklista	Chodec	Dopravní značka	Semafor	Sloup	Dopravní kužel	Jízdní kolo	Motorka	Budova	Zeleň	Kmen stromu	Silnice	Chodník	
ReDAL[15]	35.22	85.68	26.74	23.50	0.32	0.00	5.37	49.03	40.63	0.00	46.90	21.33	0.00	0.00	83.76	80.11	39.25	86.14	45.17
Our GT	29.06	68.16	18.46	20.32	0.18	0.00	0.02	27.35	34.17	0.03	38.64	9.88	0.00	0.00	73.87	76.33	31.26	83.04	41.37
Our GT-W	28.34	69.34	11.38	13.92	0.80	0.00	12.65	28.05	35.32	6.57	41.25	19.71	0.77	2.17	55.58	69.03	30.95	76.55	36.04

Jak jsou ošetřeny body, které se nově objeví ve scéně, např. Na okrajích struktur, při pohybu senzoru? Dojde k jejich označení jako dynamické/statické? Nebo tyto body autor filtruje nějakou další metodou? Mají tyto body případně vliv na celkovou přesnost metody?



Jak jsou ošetřeny body, které se nově objeví ve scéně, např. Na okrajích struktur, při pohybu senzoru? Dojde k jejich označení jako dynamické/statické? Nebo tyto body autor filtruje nějakou další metodou? Mají tyto body případně vliv na celkovou přesnost metody?



Prosím diskutujte vliv vyčlenění reálného anotátora z vyhodnocení metody a přenositelnost výsledků získaných automaticky na realitu s „human in the loop”



- Úspora času
- Simulovaný anotátor využil naši metodu pokud:
 - Navržená část mračna bodů byla alespoň z 90% sémanticky ryzí
 - Maximálně 99 bodů by bylo anotováno špatně
- Kritéria tvořena podle odhadu jak by se skutečný člověk zachoval